

Proyecto Final – Data Mining (PBL)

Transformación y Modelado de Indicadores Socioeconómicos en Latinoamérica

Objetivo del proyecto

Convertir un conjunto de datos real, ambiguo y no estructurado para machine learning en un problema bien definido de Data Mining, y resolverlo utilizando técnicas vistas en el curso.

Conjunto de datos

Este conjunto de datos contiene indicadores socioeconómicos de países latinoamericanos. Su tarea es convertirlo en un problema resoluble mediante técnicas de Data Mining.

Se les entrega el archivo: data_1777144519.xlsx

fuelle: https://statistics.cepal.org/portal/databank/index.html?lang=es&indicator_id=4987&area_id=640&members=216%2C225%2C226%2C233%2C29192%2C139212

Estructura del proyecto (5 semanas)

Semana 1 – Exploración profunda + formulación

Objetivo

Entender el conjunto de datos y proponer un problema a resolver

Entregables

1. Documento:

- ¿Qué representa el conjunto de datos?
- Problemas a resolver, potenciales (mínimo 2)

- Problema a resolver seleccionado (justificado)

2. Notebook:

- EDA inicial
- Identificación de problemas de datos

 Rúbrica (100 pts)

Criterio	Puntos
Comprensión del conjunto de datos	30
Identificación de problemas a resolver, posibles	30
Justificación del problema a resolver elegido	25
Calidad del EDA	15

 Semana 2 – Transformación del conjunto de datos

 Objetivo

Convertir el conjunto de datos, a un formato utilizable

 Entregables

1. Conjunto de datos transformado (CSV)
2. Notebook con:
 - pasos de transformación
 - justificación

 Rúbrica (100 pts)

Criterio	Puntos
Transformación correcta	40
Manejo de valores faltantes	20

Criterio	Puntos
Justificación de decisiones	20
Calidad del conjunto de datos final	20

17 **Semana 3 – Modelado inicial**

Objetivo

Construir modelos base

Entregables

Notebook con:

- Mínimo 3 modelos
- Train/Test split
- Métricas adecuadas

Rúbrica (100 pts)

Criterio	Puntos
Implementación correcta	40
Uso de métricas	30
Comparación inicial	30

17 **Semana 4 – Mejora + selección**

Objetivo

Optimizar modelos

Entregables

Notebook con:

- Validación cruzada (Cross-validation)

- Afinamiento de Hiperparámetros (Hyperparameter tuning)
- Selección final

Rúbrica (100 pts)

Criterio	Puntos
Optimización	40
Validación correcta	30
Justificación del modelo final	30

17 Semana 5 - Interpretación + presentación final

Objetivo

Explicar resultados como científicos de datos

Entregables

- Informe final
- Presentación

Rúbrica (100 pts)

Criterio	Puntos
Interpretación	40
Claridad del informe	30
Presentación	30

Reglas del proyecto

- Trabajo en grupos de 4 estudiantes
- Uso libre de librerías (sklearn, pandas, etc.)
- **Prohibido copiar notebooks completos**

- Se evaluará **explicación, no solo código**

Reglas obligatorias

1. Deben formular un problema de:
 - Clasificación **o**
 - Regresión **o**
 - Clustering
2. Deben justificar:
 - Variable objetivo (si aplica)
 - Transformaciones realizadas
3. **No pueden usar el dataset en formato original**
 - Deben transformarlo (pivot, agregación, etc.)
4. **Deben comparar, como mínimo, 3 modelos**