

Informe Final del Proyecto PRY3-MD

Angel Esteban Esquit Hernández

Roberto José Barreda Siekavizza

Javier Eduardo España Pacheco

Diego Javier López Reinoso

Resumen ejecutivo

Este proyecto desarrolló un modelo de regresión para estimar el porcentaje de uso de Internet por país, año y grupo etario en América Latina y el Caribe. A lo largo de las semanas se construyó primero una versión exploratoria del problema, luego un conjunto de datos transformado apto para machine learning, después un benchmark inicial de modelos y finalmente un proceso de ajuste con validación cruzada temporal para seleccionar el modelo definitivo.

El resultado final fue un **Gradient Boosting optimizado**. Su configuración seleccionada fue:

- `n_estimators=200`
- `max_depth=5`
- `learning_rate=0.2`
- `min_samples_leaf=2`

En el conjunto de prueba temporal 2021–2022 obtuvo **MAE = 4.97 pp**, **RMSE = 6.11 pp** y $R^2 = 0.911$. El modelo generaliza bien dentro del rango histórico observado, aunque mantiene una subestimación sistemática en los años más recientes debido al salto de adopción digital posterior a 2020.

1. Problema analítico

El objetivo del proyecto fue resolver un problema de **regresión** sobre la variable continua porcentaje de uso de Internet. La unidad de análisis corresponde a combinaciones de país, año y grupo etario. Esta formulación es adecuada porque la variable objetivo es medible en escala continua, existe una tendencia temporal clara y el comportamiento difiere de forma consistente entre países y grupos de edad.

La decisión analítica se mantuvo estable durante todo el proyecto: predecir el porcentaje de personas usuarias de Internet a partir de variables geográficas, temporales y demográficas.

2. Datos y preparación

El conjunto original presenta observaciones para países seleccionados de América Latina y el Caribe, con cobertura desde 2000 hasta 2022. El análisis exploratorio mostró tres hallazgos relevantes:

- La adopción de Internet crece con fuerza en el tiempo y muestra una tendencia no lineal.
- Existen diferencias marcadas entre países, con algunos casos sistemáticamente por encima del resto.
- La brecha generacional es persistente: los grupos jóvenes tienen valores de uso mucho más altos que los adultos mayores.

Para llevar los datos a un formato compatible con aprendizaje supervisado se aplicó una transformación que dejó el archivo listo para modelado. La versión final conserva `pais`, `anio`, `years_since_2016`, `porcentaje_internet` y variables dummy del grupo etario. Además, se restringió el análisis al período 2016–2022 por dos razones: la calidad de cobertura mejora de forma importante a partir de ese punto y el problema de predicción se vuelve más consistente cuando se evita el tramo más ruidoso del panel.

3. Metodología experimental

3.1. Secuencia de trabajo

El proyecto se organizó en cuatro etapas:

1. **Exploración inicial:** caracterización del comportamiento global, validación de cobertura y detección de patrones por país y grupo etario.
2. **Transformación:** preparación del dataset para machine learning, con codificación de categorías y creación de variables derivadas.
3. **Modelado inicial:** comparación de regresión lineal, Random Forest y Gradient Boosting como baselines.
4. **Mejora y selección:** afinamiento de hiperparámetros y validación cruzada temporal para elegir el modelo final.

3.2. Validación temporal

Para evitar fuga de información se usó una partición temporal estricta. El entrenamiento se realizó con 2016–2020 y la prueba final se reservó para 2021–2022. Sobre el conjunto de desarrollo se implementó una validación cruzada de ventana expandida con cuatro folds secuenciales, de modo que cada validación simulara la predicción de un período futuro.

Este punto es crítico desde el criterio de ciencia de datos: en un problema con componente temporal, un split aleatorio puede inflar artificialmente el desempeño y producir conclusiones optimistas que no se sostienen al llevar el modelo a observaciones futuras.

3.3. Modelos evaluados

Se evaluaron cinco configuraciones:

- Regresión lineal como baseline simple.
- Random Forest como ensamble de referencia.

- Random Forest optimizado mediante Grid Search.
- Gradient Boosting como baseline no lineal.
- Gradient Boosting optimizado como modelo candidato final.

Las métricas principales fueron MAE, RMSE y R^2 , evaluadas en validación cruzada y en el hold-out test set temporal.

4. Resultados principales

La Tabla 1 resume el desempeño de los modelos.

Cuadro 1: Comparación final de modelos

Modelo	Tipo	CV MAE (pp)	CV RMSE (pp)	CV R^2	Test MAE (pp)	Test RMSE (pp)	Test R^2
Regresión lineal	Baseline	$12,60 \pm 1,98$	$15,43 \pm 2,00$	$0,617 \pm 0,053$	8,35	10,60	0,732
Random Forest	Baseline	$6,28 \pm 1,71$	$8,06 \pm 2,61$	$0,888 \pm 0,064$	5,81	6,92	0,886
RF optimizado	Optimizado	$6,26 \pm 1,64$	$8,14 \pm 2,62$	$0,886 \pm 0,064$	5,67	6,76	0,891
Gradient Boosting	Baseline	$6,21 \pm 1,16$	$8,32 \pm 2,26$	$0,882 \pm 0,055$	5,48	6,92	0,886
GB optimizado	Optimizado	$5,33 \pm 1,17$	$7,51 \pm 2,71$	$0,900 \pm 0,063$	4,97	6,11	0,911

El patrón es claro: la regresión lineal no captura bien la no linealidad del problema, mientras que los ensambles de árboles reducen el error de forma importante. El mejor resultado lo obtuvo Gradient Boosting optimizado, que fue superior tanto en validación cruzada como en prueba final.

4.1. Parámetros seleccionados

Los mejores hiperparámetros encontrados fueron:

- **Random Forest:**

- `n_estimators=200`
- `max_depth=None`
- `max_features=1.0`
- `min_samples_leaf=1`

- **Gradient Boosting:**

- `n_estimators=200`
- `max_depth=5`
- `learning_rate=0.2`
- `min_samples_leaf=2`

La ganancia del ajuste fue baja en Random Forest y alta en Gradient Boosting. Esto sugiere que la arquitectura de boosting tenía más capacidad de aprovechar una sintonización fina del problema.

5. Análisis científico de los errores

5.1. Comportamiento global del modelo final

El Gradient Boosting optimizado obtuvo un error absoluto medio de 4.97 puntos porcentuales en prueba, con un R^2 de 0.911. En términos prácticos, el modelo explica bien la variabilidad entre países y grupos etarios y mantiene una desviación de error acotada.

Sin embargo, el error no es completamente aleatorio. El análisis de residuales mostró:

- media residual positiva de +4,57 pp,
- mediana residual de +4,14 pp,
- desviación estándar de 4,06 pp,
- subestimación en el 90 % de los casos.

Esto indica sesgo sistemático hacia valores menores que los observados. Desde una perspectiva metodológica, el comportamiento es esperable: los modelos basados en árboles interpolan bien dentro del rango de entrenamiento, pero no extrapolan con facilidad cuando el período futuro presenta una aceleración estructural como la observada tras la pandemia.

5.2. Interpretación de la subestimación

La dirección del sesgo no se interpreta como un fallo aislado del algoritmo, sino como una tensión entre la historia observada y el contexto futuro. El entrenamiento cubrió 2016–2020, mientras que la prueba incluyó 2021–2022. En ese tramo se registró una adopción digital más acelerada, por lo que varios casos reales quedaron por encima de la capacidad de extrapolación del modelo.

En otras palabras, el modelo no está mal calibrado para el pasado; está limitado para anticipar un cambio de régimen. Esta lectura es importante porque evita confundir sesgo estructural con ruido aleatorio.

5.3. Desempeño por grupos y países

Los errores no se distribuyen de manera homogénea. Los grupos etarios más altos presentan mayor dispersión, especialmente **66 años en adelante**, mientras que los grupos jóvenes son más estables. A nivel geográfico, el error fue más bajo en países con trayectorias más estables como Argentina, Costa Rica y Colombia, y más alto en países con dinámicas más abruptas como Panamá y Perú.

6. Visualizaciones de apoyo

Las figuras generadas en la semana 4 respaldan la lectura estadística del modelo final:

- comparación global de MAE y RMSE entre modelos,
- dispersión de predicho versus real,
- distribución de residuales,

- análisis de subestimación por grupos.




Figura 1: Comparación de MAE y RMSE entre los modelos evaluados.




Figura 2: Relación entre valores reales y predichos por el modelo final.

7. Conclusiones

El proyecto cumple el objetivo planteado: construir un modelo de regresión capaz de estimar el porcentaje de uso de Internet con un desempeño alto y una interpretación técnica consistente.

Las conclusiones principales son las siguientes:

1. La variable objetivo tiene una estructura predictiva fuerte y claramente asociada a tiempo, país y edad.




Figura 3: Distribución de residuales del Gradient Boosting optimizado.




Figura 4: Patrón de subestimación por grupos etarios y países.

2. La transformación del dataset fue necesaria para convertir un panel descriptivo en una tabla apta para machine learning.
3. La validación temporal fue indispensable para evitar sobreestimar el desempeño.
4. Gradient Boosting optimizado fue el mejor equilibrio entre error bajo, estabilidad y capacidad de generalización.
5. El principal límite del modelo no es la varianza, sino la extrapolación frente a un cambio de contexto histórico.

En términos de ciencia de datos, el modelo final es sólido para interpolar y para apoyar análisis comparativos entre países y grupos etarios, pero debe usarse con cautela si se pretende proyectar escenarios futuros fuera del patrón observado hasta 2020.