



UNIVERSIDAD DEL VALLE DE GUATEMALA

1CC30743020261 — Minería de Datos — Sección 30

Catedrático: Luis Furlan

Informe Final

Predicción del Porcentaje de Uso de Internet
en América Latina y el Caribe

Nombre	Carnet
Roberto Barreda	23354
Javier España	23361
Diego López	23747
Ángel Esquit	23221

Guatemala, 29 de mayo de 2026

Índice

1. Problema analítico	2
2. Marco teórico	2
2.1. Aprendizaje supervisado y regresión	2
2.2. Métodos de ensamble	2
2.3. Validación cruzada temporal	3
2.4. Datos de panel	3
3. Datos y preparación	3
4. Metodología experimental	4
4.1. Secuencia de trabajo	4
4.2. Validación temporal	4
4.3. Modelos evaluados	4
5. Resultados principales	5
5.1. Comparación de modelos	5
5.2. Hiperparámetros seleccionados	5
5.3. Visualizaciones	6
6. Análisis de errores del modelo	7
6.1. Comportamiento global del modelo final	7
6.2. Interpretación de la subestimación	7
6.3. Desempeño por grupos y países	8
7. Conclusiones	8
A. Repositorio de código	9

1. Problema analítico

El objetivo del proyecto fue cuantificar y predecir la **penetración de Internet** en países de América Latina y el Caribe, desagregada por país, año y grupo etario. Entender cómo varía el porcentaje de personas usuarias de Internet en función de estas tres dimensiones tiene valor directo para políticas públicas de inclusión digital, ya que permite identificar brechas geográficas y generacionales con precisión.

El problema se formuló como **regresión supervisada**: la variable objetivo es continua (porcentaje de uso), y las entradas son país, año y grupo etario. La unidad de análisis es cada combinación país-año-grupo, lo que convierte el problema en un panel de datos con estructura temporal y transversal.

2. Marco teórico

2.1. Aprendizaje supervisado y regresión

El **aprendizaje supervisado** es una rama del machine learning en la que un algoritmo aprende una función de mapeo a partir de pares entrada-salida etiquetados. Cuando la variable objetivo es continua, el problema se denomina **regresión**. El modelo busca minimizar un criterio de error sobre el conjunto de entrenamiento y generalizar a datos no vistos.

Las métricas estándar en problemas de regresión son el Error Absoluto Medio (MAE), la Raíz del Error Cuadrático Medio (RMSE) y el coeficiente de determinación (R^2). El MAE mide el error promedio en las mismas unidades que la variable objetivo; el RMSE penaliza más los errores grandes; y R^2 cuantifica la proporción de varianza explicada por el modelo.

2.2. Métodos de ensemble

Los **métodos de ensemble** combinan múltiples modelos base para obtener predicciones más robustas. Existen dos estrategias principales:

- **Bagging (Bootstrap Aggregating)**: construye modelos independientes en paralelo sobre muestras con reemplazo y promedia sus predicciones. **Random Forest** es el ejemplo más conocido.
- **Boosting**: construye modelos de forma secuencial, donde cada uno corrige los errores del anterior. **Gradient Boosting** entrena sucesivos árboles minimizando el gradiente de una función de pérdida, lo que le otorga alta capacidad expresiva.

2.3. Validación cruzada temporal

En problemas con componente temporal, el uso de una división aleatoria entre entrenamiento y prueba puede producir **fuga de información**: el modelo entrena sobre datos futuros y se evalúa en datos pasados, inflando artificialmente las métricas. La **validación cruzada de ventana expandida** (expanding window cross-validation) resuelve esto: en cada fold, el entrenamiento incluye todos los datos hasta un punto t y la validación se realiza sobre el período $t + 1$, simulando siempre una predicción hacia el futuro.

2.4. Datos de panel

Un **panel de datos** combina dimensiones transversales (países, grupos etarios) y una dimensión temporal (años). Este tipo de estructura presenta retos específicos: autocorrelación temporal, heterogeneidad no observada entre unidades y posibles desfases en el efecto de las variables. La correcta preparación del panel para machine learning requiere codificar las identidades de cada unidad, construir variables temporales derivadas y respetar el orden cronológico en la validación.

3. Datos y preparación

El conjunto original proviene de **CEPALSTAT** y presenta observaciones para países seleccionados de América Latina y el Caribe, con cobertura desde 2000 hasta 2022. El análisis exploratorio reveló tres hallazgos relevantes:

- La adopción de Internet crece con fuerza en el tiempo y muestra una tendencia no lineal.
- Existen diferencias marcadas entre países, con algunos casos sistemáticamente por encima del resto.
- La brecha generacional es persistente: los grupos jóvenes tienen valores de uso mucho más altos que los adultos mayores.

Para llevar los datos a un formato compatible con aprendizaje supervisado se aplicó una transformación que incluyó codificación de variables categóricas (país y grupo etario) y creación de la variable derivada `years_since_2016`. El análisis se restringió al período 2016–2022 por dos razones: la cobertura mejora de forma importante a partir de ese punto y el problema de predicción se vuelve más consistente al evitar el tramo más ruidoso del panel.

La versión final del dataset conserva: `pais`, `anio`, `years_since_2016`, `porcentaje_internet` y variables dummy del grupo etario.

4. Metodología experimental

4.1. Secuencia de trabajo

El proyecto se organizó en cuatro etapas:

1. **Exploración inicial:** caracterización del comportamiento global, validación de cobertura y detección de patrones por país y grupo etario.
2. **Transformación:** preparación del dataset para machine learning, con codificación de categorías y creación de variables derivadas.
3. **Modelado inicial:** comparación de regresión lineal, Random Forest y Gradient Boosting como baselines.
4. **Mejora y selección:** afinamiento de hiperparámetros mediante Grid Search y validación cruzada temporal para elegir el modelo final.

4.2. Validación temporal

Para evitar fuga de información se usó una partición temporal estricta. El entrenamiento se realizó con datos de 2016–2020 y la prueba final se reservó para 2021–2022. Sobre el conjunto de desarrollo se implementó una validación cruzada de ventana expandida con cuatro folds secuenciales, de modo que cada fold simulara la predicción de un período futuro.

4.3. Modelos evaluados

Se evaluaron cinco configuraciones:

- Regresión lineal como baseline simple.
- Random Forest como ensamble de referencia.
- Random Forest optimizado mediante Grid Search.
- Gradient Boosting como baseline no lineal.
- Gradient Boosting optimizado como modelo candidato final.

Las métricas principales fueron MAE, RMSE y R^2 , evaluadas tanto en validación cruzada como en el conjunto de prueba temporal.

5. Resultados principales

5.1. Comparación de modelos

El Cuadro 1 resume el desempeño de todos los modelos evaluados. El patrón es claro: la regresión lineal no captura la no linealidad del problema, mientras que los ensambles de árboles reducen el error de forma importante. El mejor resultado lo obtuvo Gradient Boosting optimizado, que fue superior tanto en validación cruzada como en prueba final.

Cuadro 1: Comparación final de modelos

Modelo	Tipo	CV MAE (pp)	CV RMSE (pp)	CV R^2	Test MAE (pp)	Test RMSE (pp)	Test R^2
Regresión lineal	Baseline	$12,60 \pm 1,98$	$15,43 \pm 2,00$	$0,617 \pm 0,053$	8,35	10,60	0,732
Random Forest	Baseline	$6,28 \pm 1,71$	$8,06 \pm 2,61$	$0,888 \pm 0,064$	5,81	6,92	0,886
RF optimizado	Optimizado	$6,26 \pm 1,64$	$8,14 \pm 2,62$	$0,886 \pm 0,064$	5,67	6,76	0,891
Gradient Boosting	Baseline	$6,21 \pm 1,16$	$8,32 \pm 2,26$	$0,882 \pm 0,055$	5,48	6,92	0,886
GB optimizado	Optimizado	$5,33 \pm 1,17$	$7,51 \pm 2,71$	$0,900 \pm 0,063$	4,97	6,11	0,911

5.2. Hiperparámetros seleccionados

Los mejores hiperparámetros encontrados mediante Grid Search se presentan en el Cuadro 2.

Cuadro 2: Hiperparámetros óptimos por modelo

Parámetro	Random Forest	Gradient Boosting
n_estimators	200	200
max_depth	None	5
learning_rate	—	0.2
max_features	1.0	—
min_samples_leaf	1	2

La ganancia del ajuste fue baja en Random Forest y alta en Gradient Boosting, lo que sugiere que la arquitectura de boosting tenía más capacidad de aprovechar la sintonización fina.

5.3. Visualizaciones




Figura 1: Comparación de MAE y RMSE entre los modelos evaluados.




Figura 2: Relación entre valores reales y predichos por el modelo final.




Figura 3: Distribución de residuales del Gradient Boosting optimizado.




Figura 4: Patrón de subestimación por grupos etarios y países.

6. Análisis de errores del modelo

6.1. Comportamiento global del modelo final

El Gradient Boosting optimizado obtuvo un MAE de 4.97 puntos porcentuales en prueba y un R^2 de 0.911, lo que indica que el modelo explica bien la variabilidad entre países y grupos etarios. Sin embargo, el error no es completamente aleatorio. El análisis de residuales mostró una media residual positiva de +4,57 pp, mediana de +4,14 pp, desviación estándar de 4,06 pp y subestimación en el 90 % de los casos.

6.2. Interpretación de la subestimación

El sesgo sistemático se explica por la tensión entre la historia observada y el contexto futuro. El entrenamiento cubrió 2016–2020, mientras que la prueba incluyó 2021–2022, período en el que se registró una adopción digital más acelerada. Los modelos basados en árboles interpolan bien dentro del rango de entrenamiento pero no extrapolan con facilidad cuando el futuro presenta una aceleración estructural. Esta lectura evita confundir sesgo estructural con ruido aleatorio.

6.3. Desempeño por grupos y países

Los errores no se distribuyen de manera homogénea. Los grupos etarios más altos (especialmente *66 años en adelante*) presentan mayor dispersión, mientras que los grupos jóvenes son más estables. A nivel geográfico, el error fue más bajo en países con trayectorias estables como Argentina, Costa Rica y Colombia, y más alto en países con dinámicas más abruptas como Panamá y Perú.

7. Conclusiones

1. La penetración de Internet en América Latina y el Caribe creció de forma sostenida entre 2016 y 2022, con una aceleración notable a partir de 2020 impulsada por la pandemia.
2. Existe una brecha generacional persistente y amplia: los grupos jóvenes (15–24 años) registran tasas de uso consistentemente superiores a las de los adultos mayores (66 años en adelante) en todos los países analizados.
3. Las diferencias entre países son significativas y estables en el tiempo; Argentina, Costa Rica y Colombia presentan los niveles de penetración más altos, mientras que otros países mantienen rezagos estructurales.
4. La brecha digital generacional no se cierra proporcionalmente con el tiempo: los grupos mayores acumulan un atraso relativo que se mantiene incluso en países con mayor desarrollo digital.
5. El año, el país y el grupo etario son los tres factores que explican la mayor parte de la variación en la penetración de Internet, confirmando que la inclusión digital es un fenómeno multidimensional.
6. La pandemia de COVID-19 introdujo una discontinuidad estructural en la adopción digital de la región: la aceleración registrada en 2021–2022 excede los patrones históricos y no es predecible a partir de datos anteriores a 2020.
7. Los países con trayectorias más abruptas o irregulares (como Panamá y Perú) evidencian que la penetración de Internet no sigue un patrón uniforme en la región, sino que depende de factores económicos e institucionales propios de cada contexto nacional.
8. Para cerrar efectivamente las brechas digitales en LATAM se requieren políticas diferenciadas: intervenciones específicas para adultos mayores y estrategias nacionales que atiendan las condiciones particulares de cada país.

A. Repositorio de código

El código fuente del proyecto, incluyendo los notebooks de exploración, transformación, modelado y evaluación, se encuentra disponible en el siguiente repositorio de GitHub:

`https://github.com/dlop6/PRY3-MD`

El repositorio contiene la estructura completa del proyecto: datos de entrada, notebooks por etapa, figuras generadas y este informe en formato L^AT_EX.