

Informe de Semana 1

PRY3-MD

1. Descripción del conjunto de datos

El conjunto de datos analiza el uso de Internet en países seleccionados de América Latina y el Caribe entre 2000 y 2022. La unidad de análisis combina tres dimensiones principales y una variable continua de interés:

- País.
- Año.
- Grupo etario.
- **Variable de interés:** porcentaje de personas usuarias de Internet (`value`).

Esta variable representa el porcentaje de personas usuarias de Internet sobre el total de personas en cada grupo etario. El archivo también contiene columnas de contexto como `indicator`, `unit`, `notes_ids` y `source_id`, útiles para trazabilidad, pero no como variables predictoras directas en un modelo.

2. EDA inicial

El análisis exploratorio realizado en el notebook `notebooks/01_semana1_eda.ipynb` muestra un comportamiento consistente con un proceso de adopción digital en expansión:

- La distribución global del porcentaje es aproximadamente simétrica, con media y mediana cercanas a 44 %.
- El rango observado va de 0 % a 97 %, lo que refleja una variabilidad amplia entre países, años y grupos etarios.
- En la comparación entre países, Uruguay, Argentina y Chile aparecen como los valores más altos, con niveles superiores al 70 % en varios cortes.
- La evolución temporal global muestra un crecimiento fuerte, pasando de niveles cercanos al 15 % en 2000 a alrededor del 72 % en 2022.
- La cobertura mejora notablemente a partir de 2016, donde el panel se vuelve mucho más confiable y homogéneo.
- Existe una brecha generacional clara: el grupo de 18 a 25 años presenta valores cercanos al 65 %, mientras que el grupo de 66 años o más se ubica alrededor del 20 %.

En conjunto, el EDA sugiere que el fenómeno está bien definido, tiene tendencia temporal visible y presenta diferencias claras por país y por edad.

3. Problemas de datos identificados

Se identificaron varios puntos críticos que conviene considerar antes de modelar:

- **Compleitud:** Con 14 países, 21 años y 5 grupos etarios, la completitud es de 49.3 % (725 combinaciones reales de 1470 posibles), reflejando un panel desbalanceado donde no todos los países tienen datos para todos los años.
- **Duplicados:** No se detectaron duplicados exactos en el dataset, lo que indica buena integridad de datos.
- **Outliers:** Presencia mínima de valores atípicos (3.4 % en el grupo 18–25 años, 6.9 % en el grupo 66+), principalmente en los extremos del rango etario.
- **Cobertura temporal:** Menor confiabilidad en los años iniciales, especialmente antes de 2016. Post-2016 el panel es más homogéneo.
- **Formato:** Dataset en formato largo que exige reestructuración (pivotaje o agregación) según el objetivo analítico.
- **Variables de contexto:** Columnas como `indicator`, `unit` y `source_id` no aportan señal directa al modelado sin tratamiento previo.

Conclusión sobre calidad: El dataset presenta buena integridad estructural (sin duplicados, variables clave íntegras). El principal limitante es el desbalance temporal. La restricción a datos post-2016 mejoraría significativamente la confiabilidad para modelado predictivo.

4. Problemas potenciales de Data Mining

4.1. Problema 1: Predicción del porcentaje de uso de Internet

- Tipo de problema: regresión.
- Qué resolvería: estimar el porcentaje de personas usuarias de Internet para una combinación de país, año y grupo etario.
- Variable objetivo: `value`.
- Transformaciones requeridas:
 - Filtrar el grupo `Total` si se busca modelar solo los grupos etarios específicos.
 - Codificar país y grupo etario.
 - Construir variables temporales, por ejemplo el año como variable numérica o con retardos.
 - Tratar los años faltantes o series incompletas.
 - Separar entrenamiento y prueba respetando el orden temporal para evitar fuga de información.

Este problema es útil porque el objetivo es continuo, el dataset tiene una tendencia clara y el comportamiento temporal ofrece señal suficiente para aprender patrones.

4.2. Problema 2: Segmentación de países o grupos etarios según su patrón de adopción

- Tipo de problema: clustering.
- Qué resolvería: agrupar países o grupos etarios con trayectorias similares de adopción de Internet.
- Variable objetivo: no aplica.
- Transformaciones requeridas:
 - Pasar de formato largo a una matriz país-año o grupo-año.
 - Estandarizar las series para comparar forma de crecimiento y no solo nivel absoluto.
 - Reducir dimensionalidad si el vector temporal es muy amplio.
 - Definir una métrica adecuada para comparar trayectorias.

Este enfoque serviría para encontrar perfiles de adopción, pero no entrega una predicción directa del porcentaje final.

5. Problema seleccionado

El problema final a resolver será la **regresión para estimar el porcentaje de uso de Internet por país, año y grupo etario**.

5.1. Justificación

Se eligió este problema por tres razones principales:

1. El EDA muestra una variable objetivo continua, clara y bien interpretada.
2. La señal temporal y la diferencia entre países y grupos etarios hacen viable un modelo supervisado con información útil.
3. La calidad del dato es razonable, sobre todo desde 2016, donde la cobertura mejora y las tendencias son más consistentes.

La clasificación no se prioriza porque requeriría discretizar artificialmente una variable continua, perdiendo información. El clustering sigue siendo útil como análisis complementario, pero no como objetivo principal del entregable por su menor capacidad de validación directa.

6. Conclusión

El conjunto de datos representa un caso sólido para analítica descriptiva y modelado predictivo básico sobre adopción digital. El comportamiento general es coherente, la brecha generacional es clara y la evolución temporal ofrece suficiente estructura para construir un primer modelo de regresión con buena viabilidad.

7. Respaldo técnico

El análisis exploratorio de respaldo se encuentra en `notebooks/01_semana1_eda.ipynb`.