

Informe de Semana 3

PRY3-MD

1. Objetivo de la semana

El objetivo de la Semana 3 fue construir un primer experimento de modelado para estimar el porcentaje de uso de Internet por país, año y grupo etario. Esta etapa se enfocó en establecer baselines, comparar modelos de regresión y preparar una primera exportación de predicciones para evaluar el comportamiento inicial del problema.

2. Datos y partición

El modelado se realizó a partir del archivo transformado de la Semana 2, que ya estaba listo para machine learning. El conjunto final usa observaciones de **2016 a 2022** y conserva la variable objetivo `porcentaje_internet` junto con las variables explicativas derivadas del país, el año y el grupo etario.

- **Entrenamiento:** observaciones de 2016 a 2020.
- **Prueba:** observaciones de 2021 a 2022.
- **Cantidad de predicciones evaluadas:** 70 filas.

La separación temporal fue importante para evitar fuga de información y simular mejor un caso real de extrapolación hacia años más recientes.

3. Preparación de variables

El notebook `notebooks/03Semana3ModeladoInicial.ipynb` implementa una codificación sencilla para poder comparar modelos con distinto nivel de complejidad.

- `pais` se codificó numéricamente para permitir su uso en modelos lineales y de árbol.
- `years_since_2016` capturó la tendencia temporal.
- Los grupos etarios se mantuvieron como variables binarias para conservar la diferencia demográfica.

Esta preparación permitió comparar modelos base sin introducir optimizaciones prematuras.

4. Modelos evaluados

Se entrenaron tres modelos de regresión como punto de partida:

- **Regresión Lineal:** baseline simple para capturar una relación aproximadamente lineal entre variables y objetivo.
- **Random Forest:** ensemble de árboles para modelar relaciones no lineales y dependencias más complejas.
- **Gradient Boosting:** ensemble secuencial para corregir errores residuales de forma gradual.

5. Resultados de evaluación

Los modelos se compararon con las métricas MAE, RMSE y R^2 sobre el conjunto de prueba 2021–2022.

Modelo	MAE (pp)	RMSE (pp)	R^2
Regresión Lineal	8.35	10.60	0.732
Random Forest	5.81	6.92	0.886
Gradient Boosting	5.48	6.92	0.886

El mejor modelo de baseline fue **Gradient Boosting**, porque obtuvo el MAE más bajo. Random Forest empató en RMSE y R^2 , pero quedó ligeramente por detrás en error absoluto medio.

6. Análisis de error

El análisis de residuales mostró un patrón consistente de subestimación en los tres modelos, especialmente en el conjunto de prueba. Esto era esperable porque 2021–2022 contiene valores más altos que los observados durante el entrenamiento, y el crecimiento de adopción digital continúa fuera del rango visto por el modelo.

- La Regresión Lineal fue el modelo menos estable, con el mayor error máximo observado.
- Los modelos de ensemble redujeron la dispersión del error y mantuvieron mejor comportamiento global.
- La importancia de variables mostró que `pais` y `years_since_2016` concentran la mayor señal predictiva.

7. Exportación de resultados

Se generó el archivo `outputs/predicciones_modelos_semana3.csv` con las predicciones de los tres modelos sobre el conjunto de prueba. Este archivo sirve como respaldo para calcular métricas, revisar residuales y construir gráficas comparativas.

8. Conclusión

Semana 3 dejó un primer benchmark sólido para el problema de regresión. El experimento confirma que el fenómeno puede modelarse con buena capacidad explicativa y que las variables temporales y geográficas son determinantes. El siguiente paso natural es ajustar hiperparámetros, mejorar la codificación de variables y revisar si una partición temporal más fina mejora la generalización.

9. Respaldo técnico

El trabajo completo de esta semana se encuentra en `notebooks/03Semana3ModeladoInicial.ipynb`. Las predicciones exportadas están en `outputs/predicciones_modelos_semana3.csv`.