

Informe de Semana 4

PRY3-MD

1. Objetivo de la semana

El objetivo de la Semana 4 consistió en mejorar los modelos predictivos iniciales de la Semana 3 mediante un diseño robusto de validación cruzada temporal y el afinamiento sistemático de hiperparámetros. El fin principal fue seleccionar y justificar técnicamente el modelo de regresión final para la estimación del porcentaje de uso de internet por país, año y grupo etario.

2. Diseño de validación cruzada y control experimental

2.1. Lógica de Partición Temporal

Para mantener coherencia y comparabilidad con los resultados previos, se conservó la estructura temporal de datos de la Semana 3:

- **Conjunto de Desarrollo (2016–2020):** Utilizado para el entrenamiento y la validación cruzada temporal.
- **Conjunto de Prueba Final (Hold-out Test, 2021–2022):** Aislado completamente durante la etapa de entrenamiento y sintonización de hiperparámetros. Se utiliza únicamente como la evaluación ciega final.

2.2. Esquema de Validación Cruzada Temporal (Anti-Leakage)

El uso de validación cruzada aleatoria convencional (K-Fold) introduce una grave fuga de información (data leakage) al mezclar observaciones del pasado y del futuro en los mismos pliegues. Para evitar esto, se implementó un esquema de ventana expandida temporal (`TemporalExpandingWindowCV`) con 4 folds secuenciales:

1. **Fold 1:** Entrena con 2016 (60 observaciones) y valida en 2017 (60 obs.).
2. **Fold 2:** Entrena con 2016–2017 (120 observaciones) y valida en 2018 (60 obs.).
3. **Fold 3:** Entrena con 2016–2018 (180 observaciones) y valida en 2019 (60 obs.).
4. **Fold 4:** Entrena con 2016–2019 (240 observaciones) y valida en 2020 (30 obs.).

Este diseño asegura que el rendimiento reportado simule fielmente la capacidad del modelo para generalizar hacia periodos futuros.

3. Afinamiento de hiperparámetros

3.1. Decisión sobre Regresión Lineal

La regresión lineal baseline de la Semana 3 obtuvo un error en validación cruzada muy elevado (CV MAE de $12,60 \pm 1,98$ pp), lo que representa más del doble del error de los modelos basados en árboles. Dado este pobre rendimiento estructural, se descartó el tuning de regularizaciones (como Ridge o Lasso) y se mantuvo como un baseline fijo de comparación.

3.2. Espacios de Búsqueda

Se utilizó `GridSearchCV` en combinación con `TemporalExpandingWindowCV` sobre los datos de desarrollo (2016–2020).

- **Random Forest:** Se evaluaron 81 combinaciones optimizando MAE negativo. Parámetros: `n_estimators` (50, 100, 200), `max_depth` (None, 5, 10), `min_samples_leaf` (1, 2, 4) y `max_features` (1.0, 'sqrt', 'log2').
- **Gradient Boosting:** Se evaluaron 81 combinaciones. Parámetros: `n_estimators` (50, 100, 200), `max_depth` (2, 3, 5), `learning_rate` (0.05, 0.1, 0.2) y `min_samples_leaf` (1, 2, 4).

3.3. Mejores Hiperparámetros Encontrados

Los mejores hiperparámetros exportados a `mejores_hiperparametros_semana4.csv` fueron:

- **Random Forest Optimizado:** `n_estimators = 200`, `max_depth = None`, `max_features = 1.0`, `min_samples_leaf = 1`.
- **Gradient Boosting Optimizado:** `n_estimators = 200`, `max_depth = 5`, `learning_rate = 0.2`, `min_samples_leaf = 2`.

4. Evaluación comparativa y resultados

El tuning produjo resultados divergentes según la arquitectura del algoritmo. Mientras que para Random Forest la mejora fue prácticamente nula debido a que los parámetros por defecto de scikit-learn ya eran óptimos (mejora en Test MAE de apenas $-0,14$ pp), para Gradient Boosting el ajuste de hiperparámetros redujo sustancialmente el error, bajando el Test MAE en $-0,51$ pp.

La Tabla 1 muestra la comparación de los 5 modelos desarrollados en esta etapa.

Cuadro 1: Tabla comparativa final de modelos (CV vs Test)

Modelo	Tipo	CV MAE (pp)	CV RMSE (pp)	CV R^2	Test MAE (pp)	Test RMSE (pp)	Test R^2
Regresión Lineal	Baseline	$12,60 \pm 1,98$	$15,43 \pm 2,00$	$0,617 \pm 0,053$	8,35	10,60	0,732
Random Forest	Baseline	$6,28 \pm 1,71$	$8,06 \pm 2,61$	$0,888 \pm 0,064$	5,81	6,92	0,886
RF Optimizado	Optimizado	$6,26 \pm 1,64$	$8,14 \pm 2,62$	$0,886 \pm 0,064$	5,67	6,76	0,891
Gradient Boosting	Baseline	$6,21 \pm 1,16$	$8,32 \pm 2,26$	$0,882 \pm 0,055$	5,48	6,92	0,886
GB Optimizado	Optimizado	$5,33 \pm 1,17$	$7,51 \pm 2,71$	$0,900 \pm 0,063$	4,97	6,11	0,911

5. Análisis de error y residuales (GB Optimizado)

Se analizó la distribución de los residuales (*Real*–*Predicho*) del mejor modelo (**Gradient Boosting Optimizado**) en el conjunto de prueba (2021–2022) para identificar posibles patrones sistemáticos de sesgo:

- **Media de residuales:** +4,57 pp.
- **Mediana de residuales:** +4,14 pp.
- **Desviación estándar:** 4,06 pp.
- **Sesgo de subestimación:** 90,0 % de los casos muestran residuales positivos (el valor real es mayor a la predicción).

5.1. Explicación del Sesgo e Impacto Histórico

Este fuerte sesgo de subestimación se explica por la evolución del contexto digital en América Latina. El modelo fue entrenado con observaciones de 2016 a 2020. Los años de prueba, 2021 y 2022, representan el periodo post-pandemia de COVID-19, el cual experimentó una aceleración masiva en la adopción tecnológica y el acceso a internet. Dado que los modelos basados en árboles no pueden extrapolar tendencias lineales más allá del rango máximo visto en las hojas del entrenamiento, las predicciones del modelo tienden a quedarse cortas frente al salto real del mercado. Sin embargo, el R^2 de 0.911 y la baja desviación estándar del error indican que el modelo sigue discriminando de manera excelente entre países y edades, manteniendo un error absoluto promedio muy bajo (4,97 pp).

5.2. Validación del Patrón de Subestimación de la Semana 3

En la Semana 3 se detectó que los modelos subestimaban sistemáticamente los valores altos de adopción de internet (> 70 pp). Los análisis de la Semana 4 confirman que este comportamiento persiste de forma generalizada en los ensambles (el RF Optimizado subestima en el 92,9 % de los casos con una media residual de +5,42 pp). No obstante, el **GB Optimizado** reduce significativamente este sesgo en comparación con los otros modelos, disminuyendo la media residual a +4,57 pp y logrando una distribución de errores mucho más centrada y simétrica.

5.3. Análisis por Grupos Etarios y Países

El MAE del Gradient Boosting Optimizado varía sustancialmente por grupo demográfico y geográfico:

- **Grupo Etario:** Los grupos de mayor adopción, como 18 a 25 años y 26 a 50 años, muestran errores pequeños. El error es notablemente más bajo que en el baseline. El grupo con mayor dispersión de error es el de adultos mayores (66 años en adelante).
- **Geografía (País):** El MAE final es excelente en países con trayectorias más estables como Argentina (3,42 pp), Costa Rica (3,69 pp) y Colombia (3,77 pp). Por el contrario, el error es mayor en Panamá (10,05 pp) y Perú (6,98 pp), lo que señala

países con dinámicas aceleradas o ruidosas que requerirán especial atención en la fase de despliegue.

6. Propuesta de modelo final y conclusión

Se propone formalmente el **Gradient Boosting Optimizado** como el modelo final para el proyecto, con la siguiente configuración: `n_estimators=200`, `max_depth=5`, `learning_rate=0.2`, `min_samples_leaf=2`.

La decisión se respalda en la solidez del protocolo experimental:

1. **Precisión Superior:** Obtuvo las mejores métricas en el hold-out test set (MAE = 4,97 pp, RMSE = 6,11 pp, $R^2 = 0.911$).
2. **Generalización Robusta:** La coincidencia entre la métrica de CV (5,33 pp) y la de Prueba (4,97 pp) demuestra que el modelo es estable y no padece de sobreajuste.
3. **Mitigación de Sesgo:** Presenta un menor sesgo sistemático de subestimación respecto a los baselines y al Random Forest optimizado.

Este modelo queda seleccionado para la fase final de visualización e interpretación (Semana 5).

7. Respaldo técnico

El código fuente completo y los experimentos ejecutados se localizan en el notebook `notebooks/04Semana4MejoraSeleccion.ipynb`. Los archivos de datos exportados se encuentran en:

- `outputs/mejores_hiperparametros_semana4.csv`: Parámetros seleccionados en Grid-SearchCV.
- `outputs/predicciones_modelo_final_semana4.csv`: Predicciones de prueba, residuales y errores absolutos por país y edad.
- `outputs/figures/semana4/`: Figuras comparativas y de residuales generadas durante el análisis.